

目标检测模型技术综述

目标检测模型技术综述：架构演进、训练方法与部署实践

本文档系统梳理目标检测领域两条主线——基于 CNN 的 YOLO 系列与基于 Transformer 的 DETR 系列——的发展演进历史、架构组件拆解、训练方法、评估指标及量化部署实践，为迈智眸算子场景选型提供技术参考。

一、什么是目标检测

目标检测（Object Detection）是计算机视觉中最基础也最成熟的任务之一，其核心目标是在图像中同时完成“是什么”（分类）和“在哪里”（定位）两个子任务——既要识别出图像中所有感兴趣目标的类别，又要精确定位每个目标的边界框（Bounding Box）。

1.1 与图像分类的本质区别

维度	图像分类	目标检测
输出	单个类别标签	N 个 (类别, 边界框) 对
空间信息	丢弃	保留并回归
目标数量	固定为 1	不定, 需自行确定
核心挑战	特征表达	特征表达 + 定位 + 密集场景去重

1.2 核心挑战

- **尺度变化**：同一类目标在不同图像中尺寸差异巨大（从 8×8 像素到覆盖全图）
- **密集场景**：目标间严重遮挡与重叠，检测器需区分相邻目标
- **小目标**：深层特征图分辨率低，小目标信息在下采样中丢失
- **实时性**：工业场景要求低延迟推理（< 30ms）

1.3 两大技术路线

目标检测的发展沿着两条主线演进：

CNN 路线：R-CNN → Fast/Faster R-CNN → YOLO v1~v12 → D-FINE

↓

Transformer 路线：DETR → Deformable DETR → RT-DETR → LW-DETR
→ RF-DETR

↓

FSDETR（频域增强）

- **CNN 路线**：基于锚框/无锚框的密集预测，依赖 NMS 后处理，工程成熟、部署友好
- **Transformer 路线**：基于集合预测的端到端检测，无需 NMS，全局建模能力强，近期在精度和速度上已追平甚至超越 CNN 路线

二、YOLO 系列：CNN 检测器的演进主线

2.1 两阶段检测器（背景知识）

在深入 YOLO 之前，需了解两阶段检测器的基本范式，因为 YOLO 的很多设计是对其的简化与改进。

R-CNN (2014) 开创了”先提候选区域再分类”的两阶段范式：

输入图像 → Selective Search 生成 ~2000 个候选区域 → 每个 ROI 独立
过 CNN → SVM 分类 + 回归

问题：速度极慢（一张图 47s），因为对 2000 个候选区域逐一做 CNN 前向。

演进链路：

模型	年份	核心改进	速度
R-CNN	2014	Selective Search + CNN + SVM	~47s/张
Fast R-CNN	2015	RoI Pooling 共享卷积特征	~0.3s/张
Faster R-CNN	2015	RPN 替代 Selective Search，端到端训练	~0.05s/张
Mask R-CNN	2017	RoI Align + 分割分支	~0.05s/张

两阶段的核心流程：

输入图像 → CNN 骨干 → FPN 多尺度特征 → RPN 生成候选框 → RoI Pooling → 分类头 + 回归头 → NMS → 输出

└ 第一阶段：生成候选类和回归 ─┘

└ 第二阶段：精确分 ─┘

2.2 YOLO 系列演进

YOLO（You Only Look Once）将检测统一为单阶段回归问题，成为实时检测的标杆。

2.2.1 架构通用范式

尽管 YOLO 版本迭代频繁，其核心架构始终遵循”骨干-颈部-头部”三段式：



组件	职责	典型实现
Backbone	提取多层次视觉特征	DarkNet (v3), CSPDarkNet (v4/v5), C2f/C3k2 (v8~v12)
Neck	融合不同分辨率特征，覆盖多尺度目标	FPN, PANet, BiFPN, ELAN-W
Head	并行预测类别概率和边界框坐标	解耦头 (Decoupled Head), Anchor-based / Anchor-free

2.2.2 关键版本里程碑

版本	年份	核心创新	意义
YOLOv1	2016	单阶段回归，7×7 网格，无锚框	首个实时检测器（45 FPS）
YOLOv2	2017	引入锚框、Batch Norm、多尺度训练	精度大幅提升
YOLOv3	2018	DarkNet-53 + FPN 三尺度预测	小目标检测能力提升
YOLOv4	2020		

版本	年份	核心创新	意义
		CSPDarkNet + PANet + Mosaic 增强	系统化训练策略整合
YOLOv5	2020	工程优化, PyTorch 原生	最广泛部署的版本
YOLOv6	2022	RepVGG 重参数化 + Decoupled Head	硬件友好的推理结构
YOLOv7	2022	E-ELAN + 辅助训练头	训练效率提升
YOLOv8	2023	Anchor-free + C2f 模块 + TaskAlignedAssigner	全面转向无锚框
YOLOv9	2024	PGI + GELAN	可编程梯度信息, 防止信息瓶颈
YOLOv10	2024	NMS-free 双标签分配	真正端到端 YOLO
YOLOv11	2024	C3k2 模块 + C2PSA 空间注意力	更轻量的特征提取
YOLOv12	2025	区域注意力机制 (A2)	CNN 中引入 Transformer 级注意力

2.2.3 Anchor-based vs Anchor-free

这是 YOLO 系列最重要的架构分水岭：

Anchor-based (YOLOv2~v7) :

特征图每个位置预设 K 个锚框（不同尺度+长宽比）
→ 回归偏移量： $\Delta x, \Delta y, \Delta w, \Delta h$ （相对于锚框）

- 分类: C 个类别概率 $\times K$ 个锚框
- NMS 去除冗余框

锚框通过 K-means 聚类数据集 GT 框得到, 需要针对不同数据集重新设计。

Anchor-free (YOLOv8+) :


特征图每个位置直接预测:

- 中心点偏移 + 框宽高 (或到四边的距离)
- 分类: C 个类别概率
- 无需锚框设计, 无需 NMS (v10+)


优势: 消除了锚框超参设计, 简化训练流程, 迁移到新数据集时更灵活。

2.2.4 核心模块演进

CSP 结构 (Cross Stage Partial) : YOLOv4 引入, 将输入特征分为两部分, 一部分走密集卷积, 另一部分直接 concat, 减少梯度重复计算:



C2f 模块 (YOLOv8) : CSPNet 的改进版, 用更少的参数获得更丰富的梯度流:



重参数化 (RepConv, YOLOv6) : 训练时用多分支结构

($3\times3+1\times1+\text{Identity}$), 推理时融合为单个 3×3 卷积, 兼顾训练效果和推理速度。

2.3 D-FINE：CNN 路线的最新进展


D-FINE (2024) 将 DETR 的最优实践融入 YOLO 框架，引入了**细粒度分布优化 (FDR)** 和 **目标感知分类 (GO-LDS)**，在 COCO 上达到 54.0 AP (small)，成为 CNN 路线精度最高的实时检测器之一。

三、DETR 系列：端到端检测的 Transformer 革命

3.1 原始 DETR (2020)：集合预测范式

DETR (DEtection TRansformer) 是 Facebook Research 在 2020 年提出的目标检测架构，**首次将 Transformer 引入目标检测**，彻底抛弃传统检测器中手工设计的组件（锚框、NMS 等），实现了真正的端到端检测。

3.1.1 架构组成



组件	职责
CNN 骨干	用 ResNet-50 提取特征图，1x1 卷积降维为序列
Transformer 编码器	自注意力建模全局关系，加位置编码
Transformer 解码器	Object Queries 通过交叉注意力”查询”目标
预测头	分类头 (C+1 类，含 $\emptyset$ 无物体类) + 回归头

3.1.2 核心思想：集合预测

DETR 将检测建模为**集合预测问题**：

- 模型输出固定 $N=100$ 个预测（覆盖大多数图像的目标数）
- 用**匈牙利算法**做二分匹配，将每个 GT 与唯一一个预测配对
- 未匹配的预测被训练输出 $\emptyset$ （无物体）
- 推理时直接扔掉 $\emptyset$ 预测，**无需 NMS**

匹配代价 = 分类损失 + L1 框损失 + GloU 损失

3.1.3 优势与不足

优势	不足
真正端到端，无需 NMS	训练收敛慢（500 epoch vs Faster R-CNN 的 12 epoch）
全局感受野，对遮挡/重叠更好	小目标性能差（仅单尺度特征）
架构简洁	推理速度不够快

3.2 DETR 家族演进


变体	年份	核心改进	解决的问题
DETR	2020	Transformer + 集合预测 + 匈牙利匹配	端到端检测范式
Deformable DETR	2020	可变形注意力 + 多尺度特征	训练加速 10 倍，小目标提升
DAB-DETR	2022	Anchor Box 作为 Query	加速收敛
DN-DETR	2022	去噪训练	进一步加速收敛
DINO	2022	对比去噪 + 混合 Query 选择	SOTA 精度
RT-DETR	2024		首个实时 DETR

变体	年份	核心改进	解决的问题
		高效混合编码器 + 不确定性最小化 Query 选择	
LW-DETR	2024	更轻量设计	RF-DETR 前身
D-FINE	2024	细粒度分布优化	CNN 框架融入 DETR 最优实践
RF-DETR	2026	NAS 搜索 + DINOv2 骨干	首个突破 60 AP 的实时检测器
FSDETR	2026	频域-空间协同 建模	小目标检测增强

3.3 RT-DETR：首个实时 DETR

RT-DETR (2024) 是百度提出的实时检测 Transformer，在速度上首次匹敌 YOLO，同时保持更高的精度。

核心创新——高效混合编码器：



关键设计：只对最高层特征做昂贵的全局注意力（因为高层特征图小，计算量可控），低层特征通过简单的卷积融合，避免了对所有尺度做注意力的计算爆炸。

3.4 RF-DETR: NAS 驱动的 SOTA

RF-DETR (ICLR 2026) 由 Roboflow 与 CMU 联合提出，通过**端到端权重共享 NAS** 一次训练即可生成从 nano 到 2x-large 的全部尺寸配置。

五大可调旋钮：

旋钮	作用	搜索空间
Patch Size	精度-延迟权衡	{8,10,12,16,20,24,32}
解码器层数	延迟控制（可降至 0 层）	{0,1,2,3,4,5,6}
Query 数量	适配目标密度	动态排序丢弃
图像分辨率	小目标 vs 速度	320~960
窗口数	注意力范围	{1,2,4}

关键成果： – RF-DETR (nano): 48.0 AP, 2.3ms, 比 D-FINE (nano) 高 5.3 AP – RF-DETR (2x-large): 60.1 AP, 首个突破 60 AP 的实时检测器 – 采用 DINOv2 自监督预训练骨干，跨域泛化能力强

3.5 FSDETR: 频域-空间协同增强小目标

FSDETR 以 RT-DETR 为基线，提出三个即插即用的改进模块：

模块	位置	核心创新
SHAB	骨干深层	只对一半通道做自注意力，省 75% 计算
DA-AIFI	编码器	可变形注意力替代全局注意力，自适应聚焦目标区域
FSFPN + CFSB	特征金字塔	频域 FFT 滤波 + 空间 Scharr 边缘提取并行融合

核心洞察：小目标的高频信号在频域是全局可见的，频域卷积以 $O(C \log N)$ 代价获得准全局感受野。在 VisDrone2019 上，FSDETR 以 14.7M 参数（比基线少 26.5%）取得 40.5 AP50 和 13.9 AP_S。

四、基于 DINO 骨干系列：自监督预训练赋能检测

4.1 为什么需要自监督预训练

预训练+下游任务微调范式的本质是**知识的复用与迁移**。然而在许多垂直领域（工业检测、医疗影像、遥感），标注数据稀缺且成本高昂，推动了自监督预训练的发展。

当前 CV 领域两大自监督范式：

范式	核心思想	代表方法
对比学习	构建正负样本对，优化相似度度量	SimCLR, MoCo, DINO
掩码图像建模 (MIM)	遮蔽图像区域，重建被遮蔽部分	MAE, BEiT, DINOv2

4.2 DINO：自监督蒸馏

DINO (Self-Supervised DINO, 2021) 的核心是**自蒸馏**：教师网络（EMA 学生网络）产生软标签，学生网络学习对齐。关键创新是用**多裁剪策略**增强正样本多样性。

4.3 DINOv2：互联网规模预训练

DINOv2 (2023) 将自监督预训练推向互联网规模：

- **训练数据：**1.42 亿张图像（LVD-142M），自动收集+去重
- **架构：**ViT (ViT-S/B/L/g)
- **方法：**结合 DINO（对比学习）+ iBOT（掩码图像建模）双重目标

- **效果**：无需任何标签，学到通用视觉特征，在 ImageNet 线性探测 86.5% Top-1

4.4 DINOv2 在检测中的应用

RF-DETR 用 DINOv2 替代传统 CNN 骨干，带来两大优势：

1. **跨域泛化**：DINOv2 的互联网规模预训练知识比 COCO 微调更通用，在 RF100-VL（100 个不同领域数据集）上泛化能力显著优于 CNN 骨干
2. **无需标签**：自监督预训练不依赖标注数据，可利用海量无标注图像

实验证明：DINOv2 骨干比 CAEv2（+1.3 AP）、SAM2 Hiera-S、SigLIPv2 均更优。

五、训练方法

5.1 数据增强

策略	描述	适用场景
Mosaic	4 图拼接，丰富背景和小目标	YOLOv4~v7
MixUp	两图加权混合	YOLOv5~v7
水平翻转 + 随机裁剪	最基础增强	RF-DETR（避免数据偏差）
Copy-Paste	从其他图复制目标粘贴	实例分割
多尺度训练	训练中随机改变输入分辨率	YOLO 全系列

RF-DETR 的反直觉发现：激进的增强（如 VerticalFlip、Mosaic）隐含对 COCO 特性的先验假设，在真实场景中可能有害。仅用翻转 + 裁剪 + EMA 调度，反而获得更好的跨域泛化。

5.2 学习率调度

调度器	描述	特点
余弦退火 (Cosine)	lr 按余弦曲线衰减到 0	YOLO 标准, 但隐含 COCO 偏差
EMA	指数移动平均, 维护权重滑动平均	RF-DETR 采用, 更温和
Linear Warmup	前几个 epoch 线性升温	稳定训练初期

5.3 损失函数

目标检测损失由三部分组成:

总损失 = $\alpha \cdot$ 分类损失 + $\beta \cdot$ 回归损失 + $\gamma \cdot$ 辅助损失

分类损失

损失	公式核心	特点
交叉熵 (CE)	$-\sum y_i \log(p_i)$	基础, 类别不平衡敏感
Focal Loss	$-\alpha(1-p)^{\gamma} \log(p)$	降低易样本权重, 聚焦难样本
Varifocal Loss (VFL)	对高 IoU 正样本加权	RT-DETR 原生, 密集场景友好

回归损失

损失	公式核心	特点
L1 / Smooth L1	$\ x_{\text{pred}} - x_{\text{gt}}\ $	稳定梯度, 但与 IoU 无关
IoU Loss	$1 - \text{IoU}$	尺度不变, 但低重叠时梯度平坦

损失	公式核心	特点
GIoU / DIoU / CIoU	IoU + 惩罚项（中心距/宽高比）	解决低重叠梯度问题
Focaler-EIoU	重构低重叠区间梯度	FSDETR 采用，小目标友好

5.4 标签分配策略

标签分配决定”哪些 anchor/query 被视为正样本”：

策略	描述	代表模型
静态 IoU 阈值	IoU > 0.5 为正，< 0.3 为负	早期 YOLO
ATSS	自适应阈值（基于统计）	大多数现代检测器
TAL (TaskAlignedAssigner)	对齐度 = 分类得分 ^α × IoU ^β	YOLOv8+
匈牙利匹配	全局最优二分匹配	DETR 系列
双标签分配 (v10)	一对多匹配（训练） + 一对一（推理）	YOLOv10 NMS-free

5.5 知识蒸馏

知识蒸馏（Knowledge Distillation）是将大模型（教师）的知识迁移到小模型（学生）的技术，是检测模型轻量化的重要手段。Meta 提出的 EUPE 方案是该领域最新代表，其核心思想是**先聚合、再蒸馏**。

EUPE 三阶段蒸馏架构

- Stage 1：多个领域专家教师 → 1.9B 代理模型（知识聚合）
- Stage 2：代理模型 → 86M 高效学生（固定 256×256 分辨率）
- Stage 3：多分辨率微调（256/384/512 三尺度）

为什么不直接多教师→小模型？ 86M 小模型直接学习 3 个 1B+ 专家会”消化不良”——多教师特征空间差异大，小模型容量不足以同时吸收。先蒸馏到 1.9B 代理模型“消化”后，再迁移给小模型，效果显著提升。

蒸馏内容：中间特征而非 Logits

EUPE 蒸馏的不是分类 logits，而是**中间特征**（class token + patch tokens）：

蒸馏对象	损失函数	作用
Class token	余弦相似度	全局语义方向对齐
Patch tokens	余弦(0.9) + Smooth L1(0.1)	空间表示对齐，保留密集预测信息

关键设计：**特征归一化**——训练前用 500 个 batch 预计算各教师输出的 per-coordinate 均值和标准差，训练中固定使用 $((y - \mu) / \sigma)$ 归一化教师输出，防止单教师主导梯度。

教师选择的反直觉发现

教师组合	效果
PEcore-G + DINOv3-H+	图像理解 + 密集预测强，但 VLM 差
+ SigLIP2-G	反而损害 OCR（两个 CLIP 类模型特征冲突）
+ PElang-G（最终选择）	OCR 与 VLM 大幅提升，不影响其他能力

启示：多教师不一定是 $1+1\geq 2$ ，需考虑特征空间兼容性。两个同类型教师（如两个 CLIP 类）可能“打架”。

对检测模型的借鉴意义

- **特征级蒸馏优于 logit 级**：保留更多空间信息，对密集预测任务尤其关键

- **代理模型策略**：当教师与学生容量差距过大时，引入中间“助教”模型可提升蒸馏效率
- **数据质量 > 数据数量**：EUPE 使用 1.69B 张 LVD 数据击败了 2.5B 张 MetaCLIP，再次验证数据质量的重要性

六、评估指标

6.1 核心指标

指标	定义	说明
AP (mAP)	PR 曲线下面积，IoU=0.5:0.95 平均	COCO 主指标
AP50	IoU=0.5 时的 AP	宽松标准，PASCAL VOC 传统
AP75	IoU=0.75 时的 AP	严格标准
AP_S	面积 < 32×32 的目标 AP	小目标检测能力
AP_M	32×32 ~ 96×96 的目标 AP	中等目标
AP_L	面积 > 96×96 的目标 AP	大目标

6.2 IoU (Intersection over Union)

$$IoU = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}$$

IoU 衡量预测框与真实框的重叠程度，范围 [0, 1]。阈值越高，对定位精度要求越严格。

6.3 速度指标

指标	定义	注意事项
FPS	每秒处理帧数	受输入分辨率影响大
延迟 (ms)	单张推理耗时	需报告硬件+精度+batch

指标	定义	注意事项
吞吐量 (img/s)	批量处理能力	受 batch size 影响

RF-DETR 的延迟标准化建议：GPU 连续推理会因功耗节流降频，应在两次前向间缓冲 200ms；精度和延迟必须用**同一模型工件**（FP16）测量，避免 FP32 报精度、FP16 报延迟的不一致问题。

七、量化部署

7.1 量化方法

方法	精度	压缩比	精度损失	适用场景
FP32	32 bit	1×	基准	训练
FP16	16 bit	2×	< 0.5 AP	GPU 推理标准
INT8	8 bit	4×	1~2 AP	边缘端/TensorRT
INT4	4 bit	8×	2~5 AP	极端资源受限

7.2 FP16 量化的陷阱

朴素 FP16 量化可能导致精度崩溃（如 D-FINE 从 55.0 AP 暴跌至 0.5 AP），根因：

- 1. ONNX 导出中的张量索引偏移在 FP16 下精度不足
- 2. 中间激活值域跨度过大，FP16 的 5 位指数无法覆盖
- 3. softmax 的指数运算放大噪声

对策：导出时检查关键算子的数值范围，必要时保留 FP32 精度的敏感层（混合精度量化）。

7.3 推理加速框架

框架	平台	特点
TensorRT	NVIDIA GPU	算子融合+内核自动调优，工业标准
ONNX Runtime	跨平台	通用性好，支持多后端
OpenVINO	Intel CPU/VPU	Intel 硬件优化
RKNN	瑞芯微	端侧 NPU 部署
CANN	华为昇腾	国产化 NPU
llama.cpp	CPU/边缘	GGUF 格式，大模型端侧

7.4 端侧部署优化策略

策略	描述	效果
算子融合	Conv+BN+ReLU 合并为一个算子	减少 kernel 启动开销
重参数化	训练多分支 → 推理单分支	零精度损失加速
结构化剪枝	移除整通道/层	减少参数和计算量
知识蒸馏	大模型教师 → 小模型学生	小模型逼近大模型精度
AWQ 量化	激活感知权重量化	比 INT8 更好的精度-效率平衡

7.5 边缘硬件选型指导

不同部署平台的算力特性差异巨大，检测模型的选型需与目标硬件匹配：

平台类型	典型硬件	算力范围	推荐模型	量化方案
NVIDIA GPU	Jetson Nano / Orin	0.5~275 TOPS	YOLOv8-s/m 或 RF-DETR-s	FP16 / TensorRT
Intel CPU				

平台类型	典型硬件	算力范围	推荐模型	量化方案
移端 NPU	i5/i7 / Xeon	依赖 AVX 指令集	YOLOv8-n/ s	INT8 / OpenVINO
	瑞芯微 RK3588	6 TOPS (NPU)	YOLOv8-n	INT8 / RKNN
	国产 NPU 华为昇腾 310/910	22~280 TOPS	YOLOv8-s/ m	INT8 / CANN
移动 CPU	iPhone 15 Pro A17	-	EUPE-ViT- T (6M, 6.8ms)	FP16 / CoreML

EUPE 端侧延迟实测参考：ViT-T (6M) 在 iPhone 15 Pro CPU 上 256×256 分辨率仅 6.8ms，证明 6M 参数级别的模型完全可落地移动端。但 ViT-B (86M) 在 512×512 分辨率下达 305ms，不适合实时场景。

部署选型决策树：

输入分辨率 ≤ 640?

└ 是 → 延迟要求 < 10ms?

└ 是 → YOLOv8-n (INT8) + TensorRT/RKNN

└ 否 → RF-DETR-nano (FP16) + TensorRT

└ 否 → 算力 > 100 TOPS?

└ 是 → RF-DETR-medium (FP16) + TensorRT

└ 否 → YOLOv8-m (INT8) + OpenVINO/CANN

7.6 国产化部署注意事项

在国产化场景（昇腾/瑞芯微）中部署检测模型需注意：

问题	原因	对策
算子不支持		降级为标准注意力或 回退到 CNN 路线

问题	原因	对策
	部分 DETR 特有算子 (如可变形注意力) 未实现	
INT8 精度退化	量化校准数据不足	使用 PTQ + QAT 混合策略，关键层保留 FP16
动态形状	NPU 通常要求固定输入尺寸	预设常用分辨率，避免运行时动态 reshape
ONNX 转换	中间表示差异	使用官方转换工具 (ATC/RKNN-Toolkit2)，避免第三方 ONNX

八、技术路线选型建议

基于迈智眸 8 大算子场景的评估，选型建议如下：

8.1 按场景特点选型

场景特点	推荐路线	推荐模型	理由
实时性要求高 (< 10ms)	CNN	YOLOv8/v11 (nano/small)	部署成熟， TensorRT 支持好
精度优先	DETR	RF-DETR (medium)	60+ AP，泛化能力强
小目标密集场景	DETR	FSDETR	频域增强， AP_S 最优
跨域泛化	DETR		

场景特点	推荐路线	推荐模型	理由
边缘端	CNN	RF-DETR + DINOv2	自监督预训练，无需大量标注
		YOLOv8 (nano) + INT8	算力受限，需极致轻量
国产化部署	CNN	YOLOv8 + CANN/RKNN	昇腾/瑞芯微算子支持完善

8.2 迈智眸算子场景分类概览

迈智眸 8 大场景共 115 个算法任务，按 CV 类型分布：

CV 类型	占比	典型算法	推荐检测器
目标检测	~70%	安全帽检测、人脸布控、车辆检测	YOLOv8/v11 或 RF-DETR
图像分割	~15%	道路破损、荒地检测、路面裂缝	U-Net / DeepLabv3+
行为识别	~8%	打架检测、跌倒检测	检测 + 时序模型 (3D CNN / Transformer)
图像分类	~5%	扬尘检测、根腐检测	ResNet / EfficientNet
计数/密度估计	~2%	人数统计、船只计数	检测 + 跟踪 / 密度图回归

目标检测是迈智眸算子场景的**核心算法类型**（占比约 70%），技术选型直接影响平台整体能力。

8.3 检测器选型决策流程

Step 1: 确定延迟要求

└─ < 5ms (极致实时) → YOLOv8-n (INT8)

└─ 5~15ms (实时) → RF-DETR-nano (FP16) 或 YOLOv8-s (INT8)

└─ 15~40ms (准实时) → RF-DETR-medium (FP16) 或 YOLOv8-m (INT8)

└─ > 40ms (离线分析) → RF-DETR-2xlarge (FP16)

Step 2: 评估目标特性

└─ 小目标密集 (航拍/监控) → FSDETR 或 YOLOv8 + 高分辨率输入

└─ 跨域泛化 (场景多变) → RF-DETR + DINOv2 骨干

└─ 常规场景 → YOLOv8/v11 标准配置

Step 3: 确认部署平台

└─ NVIDIA GPU → TensorRT FP16, 优先 RF-DETR

└─ Intel CPU → OpenVINO INT8, 选择 YOLOv8

└─ 瑞芯微/昇腾 → RKNN/CANN INT8, 选择 YOLOv8

└─ 移动 CPU → CoreML FP16, 选择 EUPE-ViT-T 或 YOLOv8-n

8.4 与相关 CV 任务的关联

目标检测并非孤立任务，迈智眸平台同时涉及多种 CV 任务类型：

相关任务	与检测的关系	技术复用
语义分割	检测给出边界框，分割给出像素级标签	共享骨干网络（如 ResNet/ViT）；DeepLab 系列的多尺度融合思想被 YOLO Neck 借鉴
实例分割	检测 + 分割的结合	RF-DETR-Seg 直接从检测模型扩展分割头；YOLO-Seg 共享检测骨干

相关任务	与检测的关系	技术复用
行为识别	检测 + 时序建模	先用检测器定位人体，再用 3D CNN / Transformer 分析动作时序
计数/密度估计	检测 + 跟踪 或 密度图回归	检测 + DeepSORT 是最成熟的计数方案

语义分割领域的 FCN 跳跃连接、DeepLab 空洞卷积与 ASPP 多尺度融合，与检测领域的 FPN/PANet 设计思想一脉相承，技术可互相借鉴。

九、总结

目标检测领域经历了从两阶段到单阶段、从 CNN 到 Transformer、从手工设计到 NAS 自动搜索的三重演进：

- 1. CNN 路线（YOLO 系列）：**工程成熟、部署友好、生态完善，是工业落地的首选。最新版本（v8~v12）已融合 Anchor-free、NMS-free、注意力机制等 DETR 优势。
- 2. Transformer 路线（DETR 系列）：**端到端、全局建模、跨域泛化强。RF-DETR 以 60.1 AP 标志着实时检测器进入新纪元，DINOv2 自监督骨干让”少标注、强泛化”成为可能。
- 3. 融合趋势：**两条路线正在融合——CNN 检测器引入 Transformer 注意力（YOLOv12），DETR 检测器采用 CNN 高效模块（RT-DETR 的 CCFM），频域增强（FSDETR）为两者提供通用增强策略。
- 4. 部署实践：**FP16 量化是 GPU 推理标准，但需警惕精度崩溃（D-FINE 从 55.0 AP 暴跌至 0.5 AP 的教训）；端侧部署需结合算子融合、结构化剪枝与知识蒸馏；国产化平台（昇腾/瑞芯微）的算子支持仍是瓶颈，DETR 特有算子可能需降级处理。

5. **训练方法论**：知识蒸馏是轻量化的关键手段——EUPE 的“先聚合再蒸馏”策略证明了特征级蒸馏优于 logit 级，多教师需考虑特征空间兼容性。数据质量 > 数据数量是颠扑不破的规律。
6. **未来趋势**：CNN 与 Transformer 两条路线正在融合（YOLOv12 引入注意力，RT-DETR 采用 CNN 模块）；自监督预训练（DINOv2）让“少标注、强泛化”成为可能；NAS 自动搜索（RF-DETR）正在取代手工架构设计。

本文档对应 OKR O2-KR1 交付物，为迈智眸算子场景选型提供技术参考依据。

十、参考文献

1. Carion et al. “End-to-End Object Detection with Transformers.” ECCV 2020.
2. Zhao et al. “RT-DETR: DETRs Beat YOLOs on Real-time Object Detection.” CVPR 2024.
3. Robinson et al. “RF-DETR: Neural Architecture Search for Real-Time Detection Transformers.” ICLR 2026.
4. Huang et al. “FSDETR: Frequency-Spatial Feature Enhancement for Small Object Detection.” 2026.
5. Oquab et al. “DINOv2: Learning Robust Visual Features without Supervision.” TMLR 2024.
6. Meta AI. “EUPE: Efficient Universal Perception Encoder.” 2026.
7. Jocher et al. “YOLOv8: A New State-of-the-Art Computer Vision Model.” 2023.
8. Wang et al. “YOLOv10: Real-Time End-to-End Object Detection.” 2024.